



# **Gestão Inteligente de Documentos**

**Arquitetura Serverless com S3 Lifecycle**

**Por:**

**Andrea Alvares Duran**

**Brenan Ulisses Araújo**

**João Marcos Lopes de Oliveira**

**Julia Kethilyn da Silva Vieira**

**Mayk Ferreira**

**Yuri Santiago Borges**

# Contexto e Justificativa do Projeto

A Startup XYZ vive um problema de crescimento: são 50 mil novos arquivos por mês chegando na plataforma, e nenhum deles pode ser descartado, porque essa base histórica é o que vai alimentar o treinamento dos futuros modelos de IA da empresa.

Quem sente essa dor não é só o cliente, que precisa continuar acessando seus documentos com agilidade — é também o time financeiro, que vê o custo de armazenamento crescer junto com o volume de arquivos, e o time de dados, que depende dessa base estar organizada e disponível.

Isso se torna urgente porque, em fase de hipercrecimento, guardar tudo sempre no mesmo nível de armazenamento sem nenhum critério torna o negócio financeiramente inviável no médio prazo.

*Por isso, a proposta é separar o ciclo de vida dos dados em duas camadas: uma "quente", com acesso rápido durante os primeiros 12 meses, quando o cliente mais usa os documentos, e uma "fria", de arquivamento de baixo custo, para preservar o histórico sem pesar no orçamento.*

# Requisitos Funcionais e Não Funcionais

Case de Arquitetura: Gestão de Documentos para IA — Startup XYZ

## 1. Requisitos Funcionais (RF)

### Ingestão de documentos

| ID   | Descrição                                                                                                                      | Prioridade |
|------|--------------------------------------------------------------------------------------------------------------------------------|------------|
| RF01 | O sistema deve permitir que o usuário envie arquivos PDF através do API Gateway, informando sua identificação (ID do usuário). | Alta       |
| RF02 | O sistema deve validar que o arquivo enviado é um PDF (tipo e tamanho) antes de processar o upload.                            | Alta       |

|      |                                                                                                                           |      |
|------|---------------------------------------------------------------------------------------------------------------------------|------|
| RF03 | O sistema deve armazenar cada arquivo no S3 usando o ID do usuário como prefixo da chave (ex: usuario-123/documento.pdf). | Alta |
|------|---------------------------------------------------------------------------------------------------------------------------|------|

### Acesso e recuperação

| ID   | Descrição                                                                                                                              | Prioridade |
|------|----------------------------------------------------------------------------------------------------------------------------------------|------------|
| RF04 | O sistema deve permitir que o usuário recupere/visualize seus próprios documentos enviados nos últimos 12 meses.                       | Alta       |
| RF05 | A Lambda deve gerar uma URL assinada (pre-signed URL) com tempo de expiração para acesso temporário ao arquivo.                        | Alta       |
| RF06 | O sistema não deve permitir que um usuário acesse arquivos pertencentes a outro usuário, mesmo que tente manipular o ID na requisição. | Alta       |

### Ciclo de vida dos dados

| ID   | Descrição                                                                                                                                          | Prioridade |
|------|----------------------------------------------------------------------------------------------------------------------------------------------------|------------|
| RF07 | O sistema deve mover automaticamente arquivos com mais de 365 dias para uma camada de armazenamento de baixo custo (fria), sem exigir ação manual. | Alta       |
| RF08 | Nenhum arquivo deve ser deletado do sistema, independentemente do tempo de armazenamento (retenção histórica para treinamento de IA).              | Alta       |

### Monitoramento

| ID   | Descrição                                                                                       | Prioridade |
|------|-------------------------------------------------------------------------------------------------|------------|
| RF09 | O sistema deve registrar logs de cada requisição (upload, acesso, erro) para fins de auditoria. | Média      |
| RF10 | O sistema deve permitir que o engenheiro de cloud consulte métricas e logs via CloudWatch.      | Média      |

## 2. Requisitos Não Funcionais (RNF)

### Segurança

| ID    | Descrição                                                                                                                                          | Prioridade |
|-------|----------------------------------------------------------------------------------------------------------------------------------------------------|------------|
| RNF01 | O bucket S3 deve ter Block Public Access habilitado — nenhum objeto pode ser acessado publicamente sem URL assinada.                               | Alta       |
| RNF02 | O acesso deve seguir o princípio do menor privilégio via políticas IAM, restringindo cada execução da Lambda ao prefixo do usuário correspondente. | Alta       |
| RNF03 | Todos os dados devem ser criptografados em trânsito (HTTPS/TLS) e em repouso (SSE no S3).                                                          | Alta       |

### Custo

| ID    | Descrição                                                                                                                                                          | Prioridade |
|-------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------|
| RNF04 | A arquitetura deve ser financeiramente sustentável mesmo com o crescimento de 50 mil arquivos/mês, evitando custo linear de armazenamento por meio da camada fria. | Alta       |
| RNF05 | A solução deve utilizar modelo de cobrança sob demanda (pay-per-use) — sem servidores provisionados ociosos (serverless).                                          | Média      |

### Escalabilidade e desempenho

| ID    | Descrição                                                                                                                       | Prioridade |
|-------|---------------------------------------------------------------------------------------------------------------------------------|------------|
| RNF06 | O sistema deve suportar picos de upload sem degradação perceptível, aproveitando o auto-scaling nativo do API Gateway e Lambda. | Média      |
| RNF07 | A geração da URL assinada deve responder em tempo aceitável para uma boa experiência do usuário (ex: menor que 2 segundos).     | Média      |

### Disponibilidade e confiabilidade

| ID    | Descrição                                                                                                                                                | Prioridade |
|-------|----------------------------------------------------------------------------------------------------------------------------------------------------------|------------|
| RNF08 | O sistema deve utilizar serviços gerenciados pela AWS (S3, Lambda, API Gateway) para garantir alta disponibilidade sem gestão de infraestrutura própria. | Alta       |
| RNF09 | A durabilidade dos dados armazenados deve seguir o SLA do S3 (99,999999999% de durabilidade).                                                            | Alta       |

## Auditoria e observabilidade

| ID    | Descrição                                                                                                   | Prioridade |
|-------|-------------------------------------------------------------------------------------------------------------|------------|
| RNF10 | Todas as ações críticas (acesso, upload, transição de lifecycle) devem ser rastreáveis via CloudWatch Logs. | Média      |

## Justificativa do Uso de Cada Serviço

A seguir, o racional de escolha de cada serviço AWS utilizado na arquitetura e a maneira como cada um calcula seus custos.

### Amazon API Gateway

Foi escolhido como porta de entrada da aplicação porque expõe um endpoint HTTP gerenciado, escalável e sem necessidade de provisionar servidor, exatamente o perfil de uma arquitetura serverless. Ele recebe os uploads dos clientes já validando aspectos básicos da requisição antes de acionar a lógica de negócio.

**Cobrança:** por número de requisições recebidas (cobrado por milhão de chamadas), somado, se aplicável, ao volume de dados transferido. Não há custo fixo mensal nem custo por servidor ocioso — se não houver requisições, não há cobrança.

### AWS Lambda

Foi escolhida para processar a lógica de recebimento e geração de acesso aos arquivos porque permite executar código sob demanda, sem manter uma instância de servidor rodando continuamente. Isso é essencial para o modelo de negócio, já que o volume de uploads (50 mil arquivos/mês) pode variar bastante ao longo do tempo, e a Lambda escala automaticamente conforme a demanda.

**Cobrança:** por número de execuções (invocations) e pelo tempo de execução multiplicado pela memória alocada (medido em GB-segundo). Ou seja, o custo é proporcional ao uso real — uma função que roda por poucos milissegundos custa uma fração de centavo por execução.

### Amazon S3

Foi escolhido como repositório principal por ser um serviço de armazenamento de objetos duráveis, escalável e de baixo custo, ideal para guardar grandes volumes de arquivos não-estruturados (PDFs e imagens) sem se preocupar com capacidade de disco. Além disso, o S3 permite configurar regras de Lifecycle, que automatizam a movimentação de arquivos entre camadas de armazenamento sem intervenção manual — peça-chave para resolver o desafio de custo do case, já que nenhum arquivo pode ser deletado.

**Cobrança:** por GB armazenado por mês (o valor varia conforme a classe de armazenamento), por número de requisições (leitura/escrita) e por volume de dados transferido para fora da AWS. A camada "quente" (S3 Standard, usada nos primeiros 12 meses) tem custo de armazenamento mais alto, mas requisições rápidas e baratas. A camada "fria" (Glacier ou Glacier Deep Archive, usada após 365 dias) tem custo de armazenamento drasticamente menor — o que sustenta a estratégia de manter o histórico completo sem inviabilizar o negócio financeiramente — mas cobra tarifas maiores para recuperar (restaurar) um arquivo, o que é aceitável já que esses dados são de acesso raro.

### AWS IAM

Foi utilizado para garantir o isolamento entre usuários, exigência central de segurança do case. Por meio de uma role de execução atribuída à Lambda, o IAM restringe as ações que a função pode realizar no S3 (agindo apenas sobre o prefixo do usuário correspondente), e por meio de uma bucket policy, garante que o bucket nunca fique exposto publicamente (Block Public Access habilitado).

**Cobrança:** o IAM não gera custo direto — é um serviço gratuito da AWS, usado para definir e aplicar permissões sobre os demais recursos.


### Amazon CloudWatch

Foi incluído para dar visibilidade operacional ao sistema, permitindo que o time de engenharia monitore erros, tempo de resposta das Lambdas e volume de requisições, além de auditar acessos aos documentos — requisito de rastreabilidade importante numa aplicação que lida com dados sensíveis dos clientes.

**Cobrança:** por volume de logs e métricas ingeridos e armazenados (cobrado por GB), além de eventuais alarmes e dashboards customizados configurados.

# Arquitetura da Solução

## Gestão de Documentos para IA—Startup—Arquitetura Serverless



## Aderência aos 6 Pilares do AWS Well-Architected Framework

- Operational Excellence (CloudWatch logs, monitoring)
- Security (IAM, Encryption, Block Public Access)
- Reliability (S3 managed, escalável)
- Performance Efficiency (Serverless, auto-scaling)
- Cost Optimization (Pay-per-use, Lifecycle S3)
- Sustainability (uso eficiente de recursos)

# Estimativa de Custos da Arquitetura

*Case de Arquitetura: Gestão de Documentos para IA — Startup XYZ*

## 1. Premissas Assumidas

Os valores abaixo foram estimados com o AWS Pricing Calculator, considerando as seguintes premissas para simular o comportamento da plataforma em regime de operação:

- Volume de entrada: 50.000 novos arquivos por mês, conforme informado no case.
- Tamanho médio de arquivo: 800 KB (PDFs com múltiplas páginas e conteúdo apto a OCR/extração por IA).
- Reacessos: estimativa de 2 a 3 acessos por documento após o upload (cliente reabrindo, reprocessamento, auditoria), totalizando ~100.000 requisições de leitura/mês.
- Horizonte de simulação: 3 anos de operação, no chamado "estado estável"
- (steady state) — quando o volume que entra na camada quente se equilibra com o volume que migra para a camada fria a cada mês.
- Região: uma única região AWS, sem tráfego entre regiões.
- Retenção de logs: 30 dias no CloudWatch.

Por se tratar de estimativas, os valores reais podem variar conforme o comportamento real dos usuários, a região da AWS utilizada e eventuais mudanças na tabela de preços oficial da AWS.



## 2. Estimativa de Custo Mensal por Serviço

| Serviço                               | Premissas de uso                                                       | Custo mensal      |
|---------------------------------------|------------------------------------------------------------------------|-------------------|
| Amazon API Gateway                    | 100.000 requisições/mês (upload + reaccessos), 800 KB médios           | US\$ 0,20         |
| AWS Lambda                            | 100.000 execuções/mês, 400 ms, 512 MB (dentro do free tier)            | US\$ 0,00         |
| Amazon S3 Standard (quente)           | 458 GB armazenados (12 meses de acúmulo), 50 mil PUT + 100 mil GET/mês | US\$ 10,82        |
| Amazon S3 Glacier Deep Archive (fria) | 916 GB armazenados (24 meses de acúmulo), 50 mil transições/mês        | US\$ 3,75         |
| Data Transfer (saída p/ internet)     | 76 GB/mês transferidos (downloads via URL assinada)                    | US\$ 6,84         |
| Amazon CloudWatch                     | 1 GB de logs/mês, 1 dashboard, 3 alarmes de resolução padrão           | US\$ 0,80         |
| <b>TOTAL MENSAL ESTIMADO</b>          |                                                                        | <b>US\$ 22,41</b> |

## 3. Comparativo: Camada Quente vs. Camada Fria

| Métrica                       | S3 Standard (quente) | Glacier Deep Archive (fria) |
|-------------------------------|----------------------|-----------------------------|
| Volume armazenado             | 458 GB               | 916 GB                      |
| Custo mensal de armazenamento | US\$ 10,53           | US\$ 0,91                   |
| Custo aproximado por GB       | ~US\$ 0,0236/GB      | ~US\$ 0,0041/GB             |

*Mesmo armazenando o dobro do volume, a camada fria custa aproximadamente 3 vezes menos que a camada quente por GB — resultado que confirma numericamente a decisão de arquitetura de mover arquivos com mais de 365 dias para uma classe de armazenamento de baixo custo, sem a necessidade de deletar nenhum dado histórico.*

## 4. Conclusões

- O processamento (API Gateway + Lambda) é praticamente gratuito neste volume, somando apenas US\$ 0,20/mês — a arquitetura serverless entrega o modelo de cobrança sob demanda que o negócio precisa em fase de hipercrescimento.
- O armazenamento é o principal componente de custo da arquitetura, respondendo por cerca de 65% do total (S3 Standard + Glacier), o que confirma a dor central descrita no case.
- A camada fria (Glacier Deep Archive) é significativamente mais eficiente por GB armazenado que a camada quente, validando a estratégia de Lifecycle como forma de reter o histórico completo sem inviabilizar o negócio financeiramente.
- A transferência de dados para a internet (download dos documentos pelos clientes) representa um custo relevante (US\$ 6,84/mês) e deve ser monitorada conforme a base de usuários crescer.
- O custo total estimado de US\$ 22,41/mês, considerando 3 anos de operação e aproximadamente 1,4 TB de dados acumulados, demonstra que a arquitetura proposta é financeiramente sustentável mesmo em um cenário de crescimento acelerado.

*Observação: os valores apresentados são estimativas obtidas por meio do AWS Pricing Calculator (calculator.aws), com base nas premissas descritas na Seção 1. Recomenda-se revisão periódica dessas estimativas conforme o comportamento real de uso da plataforma e eventuais alterações na tabela de preços da AWS.*